

Trabajo Práctico 1: Modelado Estadístico

Sebastian Souto y Santiago Chiquinho

2026-06-22

1: Exploración Inicial

El **Austin Animal Center** es el refugio de animales municipal más grande de Estados Unidos. Cada animal que ingresa tiene, eventualmente, un desenlace: puede ser **adoptado**, **devuelto** a su dueño, **transferido** a otra organización, o sufrir **eutanasia/muerte**. El refugio publica todos sus registros de ingresos y egresos.


Para este trabajo se utilizará el dataset `refugio.csv`. Es un dataset (derivado de los registros públicos de `data.austintexas.gov`) en donde cada fila es un animal (perro o gato), con su tiempo de estadía y su desenlace.

Realizaremos una exploración inicial para conocer los datos:

Número de animales:

`## Cantidad de animales: 137806`

Distribución de desenlaces:



Se puede observar que el desenlace más común en los datos es “Adopción” por amplia mayoría.

Summary

Con el comando summary tenemos un resumen de cada columna del dataset.

```
##      animal_type      dog      sexo      sterilized
## Length :137806 Min. :0.0000 Length :137806 Min. :0.000
## N.unique : 2 1st Qu.:0.0000 N.unique : 2 1st Qu.:0.000
## N.blank : 0 Median :1.0000 N.blank : 0 Median :0.000
## Min.nchar: 3 Mean :0.5633 Min.nchar: 5 Mean :0.206
## Max.nchar: 3 3rd Qu.:1.0000 Max.nchar: 6 3rd Qu.:0.000
## Max. :1.0000 Max. :1.000
##      age_years      breed_main      los      desenlace
## Min. : 0.000 Length :137806 Min. : 0.00 Length :137806
## 1st Qu.: 0.083 N.unique : 473 1st Qu.: 3.11 N.unique : 4
## Median : 1.000 N.blank : 0 Median : 6.86 N.blank : 0
## Mean : 1.886 Min.nchar: 3 Mean : 20.68 Min.nchar: 6
## 3rd Qu.: 2.000 Max.nchar: 38 3rd Qu.: 23.06 Max.nchar: 13
## Max. :24.000 Max. :364.90
```

Del summary podemos destacar que:

- 56.33% de los animales son perros y el resto gatos.
- Hay solo dos categorías para sexo y no hay datos faltantes.
- Aproximadamente el 20% de los animales están esterilizados.
- La mayoría de los animales son "jóvenes". El 25% de ellos tiene menos de 0.083 años (~ 1 mes), la mediana es 1 año y el 75% tiene menos de 2 años. Existen algunos animales muy viejos, hasta 24 años.
- Hay 473 razas distintas.
- En promedio los animales pasan 20.68 días en el refugio. Y el 75% pasa menos de 23 días.

Glimpse


Con el comando glimpse vemos el tipo de datos de cada columna y algunos valores de las columnas.

```
## Rows: 137,806
## Columns: 8
## $ animal_type <chr> "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "C~
## $ dog <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1~
## $ sexo <chr> "Macho", "Macho", "Macho", "Hembra", "Hembra", "Macho", "M~
## $ sterilized <dbl> 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1~
## $ age_years <dbl> 6, 10, 16, 15, 15, 15, 15, 18, 16, 14, 16, 14, 17, 13, 19,~
## $ breed_main <chr> "Spinone Italiano Mix", "Dachshund", "Shetland Sheepdog", ~
## $ los <dbl> 1.11, 4.97, 0.12, 0.87, 0.18, 0.21, 6.26, 0.05, 3.90, 14.1~
## $ desenlace <chr> "Devolucion", "Transferencia", "Devolucion", "Devolucion",~
```


Exploración Adicional

Realizaremos una exploración un poco más exhaustiva de los datos.

Sexo




Veamos si estas cantidades se mantienen separando por perros y gatos.



En los gatos hay más hembras que machos. Mientras que en los perros sucede lo contrario.


Edades

Como habíamos visto en el summary, la mayor parte de los animales son jóvenes. Veamos si hay alguna diferencia si separamos entre perros y gatos.



En los histogramas divididos por tipo de animal notamos que los gatos tienen mayor concentración en edades que no llegan al año. Más del 70% de los gatos caen en este grupo, mientras que con los perros no sucede lo mismo.


Desenlaces según esterilización




En la mayoría de los desenlaces, la proporción de animales esterilizados y no esterilizados es similar a la observada en la muestra total. Sin embargo, en la categoría “Devolución” se observa una proporción considerablemente mayor de animales esterilizados, cercana al 50%, a pesar de que los animales esterilizados representan aproximadamente el 20% de la muestra.

Esto se puede deber a que los animales esterilizados tienen más probabilidad de tener un dueño previo. Y que este dueño lo reclame.

Tiempo de estadía



Los días de estadía muestran una distribución con una cola larga hacia la derecha. Y con acumulación en los primeros días



Se observa que el desenlace con días de estadía más variado es adopción. Y también el que tiene mediana mayor. Y se observa que la devolución no es tan variada.

2: Estadística Bayesiana

Queremos estimar la tasa de adopción de cada raza. La estimación “obvia” es la tasa cruda: adoptados sobre total. Vamos a medir si conviene usar esa tasa o el estimador de Empirical Bayes.


Calculamos la “tasa verdadera” de cada raza como su tasa de adopción sobre toda la data (nos quedamos únicamente con raza que tengan al menos 100 animales).

```
## # A tibble: 6 x 4
```

```
##   breed_main          n adoptados tasa_verdadera
##   <chr>          <int>      <int>      <dbl>
## 1 Domestic Shorthair Mix 28638    14370      0.502
## 2 Domestic Shorthair    21359    13137      0.615
## 3 Pit Bull Mix          7456     3274      0.439
## 4 Labrador Retriever Mix  7187     4137      0.576
## 5 Chihuahua Shorthair Mix 6041     2948      0.488
## 6 Labrador Retriever    3913     2175      0.556
```

Vamos a simular el problema de estimar con poca data para ver como afecta esto. Tomamos una muestra aleatoria chica de cada raza y probamos.

Veamos gráficamente las diferencias:



En el gráfico podemos observar, que al tomar muestras más chicas, la estimación varía.