

Trabajo Práctico 1: Modelado Estadístico

Sebastian Souto y Santiago Chiquinho

2026-06-26

1: Exploración Inicial

El **Austin Animal Center** es el refugio de animales municipal más grande de Estados Unidos. Cada animal que ingresa tiene, eventualmente, un desenlace: puede ser **adoptado**, **devuelto** a su dueño, **transferido** a otra organización, o sufrir **eutanasia/muerte**. El refugio publica todos sus registros de ingresos y egresos.


Para este trabajo se utilizará el dataset `refugio.csv`. Es un dataset (derivado de los registros públicos de `data.austintexas.gov`) en donde cada fila es un animal (perro o gato), con su tiempo de estadía y su desenlace.

Realizaremos una exploración inicial para conocer los datos:

Número de animales:

Tenemos datos de 137806 animales.

Distribución de desenlaces:



Se puede observar que el desenlace más común en los datos es “Adopción” por amplia mayoría.

Summary

Con el comando `summary` tenemos un resumen de cada columna del dataset.

```
##      animal_type      dog      sexo      sterilized
## Length :137806   Min.   :0.0000   Length :137806   Min.   :0.000
## N.unique :      2   1st Qu.:0.0000   N.unique :      2   1st Qu.:0.000
## N.blank  :      0   Median :1.0000   N.blank  :      0   Median :0.000
## Min.nchar:      3   Mean    :0.5633   Min.nchar:      5   Mean    :0.206
## Max.nchar:      3   3rd Qu.:1.0000   Max.nchar:      6   3rd Qu.:0.000
##                               Max.   :1.0000                               Max.   :1.000
##      age_years      breed_main      los      desenlace
## Min.   : 0.000   Length :137806   Min.   : 0.00   Length :137806
## 1st Qu.: 0.083   N.unique :   473   1st Qu.: 3.11   N.unique :      4
## Median : 1.000   N.blank  :      0   Median : 6.86   N.blank  :      0
## Mean    : 1.886   Min.nchar:      3   Mean    :20.68   Min.nchar:      6
## 3rd Qu.: 2.000   Max.nchar:     38   3rd Qu.:23.06   Max.nchar:     13
## Max.    :24.000                               Max.    :364.90
```

Del summary podemos destacar que:

- 56.33% de los animales son perros y el resto gatos.
- Hay solo dos categorías para sexo y no hay datos faltantes.
- Aproximadamente el 20% de los animales están esterilizados.
- La mayoría de los animales son “jóvenes”. El 25% de ellos tiene menos de 0.083 años (~ 1 mes), la mediana es 1 año y el 75% tiene menos de 2 años. Existen algunos animales muy viejos, hasta 24 años.
- Hay 473 razas distintas.
- En promedio los animales pasan 20.68 días en el refugio. Y el 75% pasa menos de 23 días.

Glimpse


Con el comando “`glimpse()`” vemos el tipo de datos de cada columna y algunos valores de las mismas.

```
## Rows: 137,806
## Columns: 8
## $ animal_type <chr> "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "C~
## $ dog         <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1~
## $ sexo        <chr> "Macho", "Macho", "Macho", "Hembra", "Hembra", "Macho", "M~
## $ sterilized  <dbl> 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1~
## $ age_years   <dbl> 6, 10, 16, 15, 15, 15, 15, 18, 16, 14, 16, 14, 17, 13, 19,~
## $ breed_main  <chr> "Spinone Italiano Mix", "Dachshund", "Shetland Sheepdog", ~
## $ los         <dbl> 1.11, 4.97, 0.12, 0.87, 0.18, 0.21, 6.26, 0.05, 3.90, 14.1~
## $ desenlace   <chr> "Devolucion", "Transferencia", "Devolucion", "Devolucion",~
```


Exploración Adicional

Realizaremos una exploración un poco más exhaustiva de los datos.

Sexo




Veamos si estas cantidades se mantienen separando por perros y gatos.



En los gatos hay más hembras que machos. Mientras que en los perros sucede lo contrario.


Edades

Como habíamos visto en el summary, la mayor parte de los animales son jóvenes. Veamos si hay alguna diferencia si separamos entre perros y gatos.



En los histogramas divididos por tipo de animal notamos que los gatos tienen mayor concentración en edades que no llegan al año. Más del 70% de los gatos caen en este grupo, mientras que con los perros no sucede lo mismo.


Desenlaces según esterilización




En la mayoría de los desenlaces, la proporción de animales esterilizados y no esterilizados es similar a la observada en la muestra total. Sin embargo, en la categoría “Devolución” se observa una proporción considerablemente mayor de animales esterilizados, cercana al 50%, a pesar de que los animales esterilizados representan aproximadamente el 20% de la muestra.

Esto se puede deber a que los animales esterilizados tienen más probabilidad de tener un dueño previo. Y que este dueño lo reclame.

Tiempo de estadía



Los días de estadía muestran una distribución con una cola larga hacia la derecha. Y con acumulación en los primeros días



Se observa que el desenlace con días de estadía más variado es adopción. Y también el que tiene mediana mayor. Y se observa que la devolución no es tan variada.

2: Estadística Bayesiana

Queremos estimar la tasa de adopción de cada raza. La estimación “obvia” es la tasa cruda: adoptados sobre total. Vamos a medir si conviene usar esa tasa o el estimador de Empirical Bayes.


Calculamos la “tasa verdadera” de cada raza como su tasa de adopción sobre toda la data (nos quedamos únicamente con raza que tengan al menos 100 animales).

Table 1: Tasa verdadera de adopción por raza

Raza	Total	Adoptados	Tasa verdadera
Domestic Shorthair Mix	28638	14370	0.502
Domestic Shorthair	21359	13137	0.615
Pit Bull Mix	7456	3274	0.439
Labrador Retriever Mix	7187	4137	0.576
Chihuahua Shorthair Mix	6041	2948	0.488
Labrador Retriever	3913	2175	0.556

Vamos a simular el problema de estimar con poca data para ver cómo afecta esto. Tomamos una muestra aleatoria chica de cada raza y probamos.

Veamos gráficamente las diferencias:



En el gráfico podemos observar, que al tomar muestras más chicas, la estimación varía.

Estimador Empirical Bayes

Para calcular el estimador Empirical Bayes ajustamos una prior Beta sobre las tasas crudas de adopción observadas en las muestras chicas por raza.

Como la distribución Beta está definida en el intervalo abierto entre 0 y 1, primero corregimos levemente las tasas crudas que sean exactamente 0 o exactamente 1. Esto puede pasar porque estamos usando muestras chicas de 15 animales por raza.

Luego ajustamos la distribución Beta usando máxima verosimilitud sobre las tasas de adopción ajustadas.

Los parámetros estimados fueron:

- $\alpha_0 = 2.499$
- $\beta_0 = 2.851$

Estos parámetros se utilizarán para definir la distribución **a priori** de la tasa de adopción de cada raza.

A continuación, calculamos el estimador Empirical Bayes para la tasa de adopción de cada raza. Dado que se asume una distribución Beta como prior y que el número de adopciones sigue una distribución Binomial, la distribución posterior es una Beta. Como estimador utilizamos la esperanza de la distribución posterior, dada por:

$$\hat{p}_i^{EB} = E[p_i | \text{datos}_i] = \frac{\alpha_0 + \text{adoptados}_i}{\alpha_0 + \beta_0 + m}$$

Calculamos el estimador para cada raza y observamos la comparación.

«««< HEAD

Table 2: Comparación de tasas: cruda, Empirical Bayes y verdadera

Raza	Adopciones (m=15)	Tasa cruda	Empirical Bayes	Tasa verdadera
Domestic Shorthair Mix	5	0.333	0.369	0.502
Domestic Shorthair	13	0.867	0.762	0.615
Pit Bull Mix	7	0.467	0.467	0.439
Labrador Retriever Mix	10	0.667	0.614	0.576
Chihuahua Shorthair Mix	5	0.333	0.369	0.488
Labrador Retriever	8	0.533	0.516	0.556

El estimador Empirical Bayes combina la información observada para cada raza con una prior estimada a partir del comportamiento general de todas las razas. La tasa cruda puede ser muy inestable porque se calcula con solo 15 animales por raza. El estimador suaviza ese valor, acercándolo hacia la distribución general de tasas de adopción entre razas.

La comparación (métrica)


Con el fin de seleccionar un estimador por sobre el otro, calculamos el ECM de ambos contra la tasa verdadera. La tasa verdadera fue calculada usando toda la base, mientras que la tasa cruda y el estimador Empirical Bayes fueron calculados usando únicamente las muestras chicas de 15 animales por raza.

Table 3: Comparación del ECM entre estimadores

Estimador	Error cuadrático medio
Tasa cruda	0.015012
Empirical Bayes	0.009481

La mejora porcentual del Empirical Bayes respecto de la tasa cruda es de : 36.84%.

El estimador Empirical Bayes redujo el error cuadrático medio en aproximadamente un 36.84% respecto de la tasa cruda. Esto indica que, en este contexto de muestras chicas por raza, el suavizado bayesiano mejora la estimación de la tasa de adopción. Lo vemos más claramente con el siguiente gráfico.



La línea roja representa el caso ideal, en el que la tasa estimada coincide exactamente con la tasa verdadera. Los puntos más cercanos a esa línea corresponden a mejores estimaciones. Vemos que:

- La tasa cruda presenta mayor variabilidad porque se calcula con solo 15 animales por raza. Por eso, algunas razas pueden quedar con tasas altas o bajas por efecto del azar muestral.
- El estimador Empirical Bayes suaviza esas tasas, combinando la información observada en cada raza con la información general aprendida a partir del conjunto de razas.

Si su ECM resulta menor, podemos concluir que Empirical Bayes mejora la estimación frente a la tasa cruda en este contexto de poca información por raza.

3: Modelo Multinomial

Para estos datos, si queremos modelar la probabilidad de los distintos desenlaces, no podemos utilizar una regresión logística binaria porque la variable respuesta tiene más de dos categorías posibles. En su lugar, se puede utilizar un modelo multinomial, que permite estimar la probabilidad de cada desenlace en función de las covariables observadas. Los parámetros del modelo se estiman mediante máxima verosimilitud, suponiendo que la variable respuesta sigue una distribución multinomial. Se fija una categoría de referencia y se modelan las probabilidades de la siguiente manera para cumplir con la restricción de que las probas sumen 1:

$$p_j(x) = \frac{\exp(\alpha_j + \beta_j x)}{1 + \sum_{l=2}^K \exp(\alpha_l + \beta_l x)}$$

$$p_1(x) = \frac{1}{1 + \sum_{l=2}^K \exp(\alpha_l + \beta_l x)}$$

1 siendo la categoría de referencia y j cualquier otra categoría

La función de verosimilitud que se maximiza es:

$$L(\theta) = \prod_{i=1}^n \prod_{j=1}^K p_j(x_i)^{y_{ij}}$$

donde y_{ij} es una variable indicadora que toma valor 1 si la observación i pertenece a la categoría j , y 0 en caso contrario.

Ajustamos un modelo multinomial de 4 categorías en función de age_years, dog, sterilized y sexo. Con Adopción como referencia.

Y obtenemos los siguientes resultados:

Table 4: Coeficientes del modelo multinomial

	(Intercept)	age_years	dog	sterilized	sexoMacho
Devolucion	-3.4748	0.1662	1.7009	1.2524	0.2736
Muerte	-2.8917	0.2428	-0.7076	-0.3782	0.2582
Transferencia	-0.4906	0.0809	-0.4258	-0.2241	-0.0021

Table 5: Errores estándar del modelo multinomial

	(Intercept)	age_years	dog	sterilized	sexoMacho
Devolucion	0.0258	0.0031	0.0239	0.0206	0.0176
Muerte	0.0273	0.0046	0.0302	0.0424	0.0296
Transferencia	0.0112	0.0031	0.0128	0.0203	0.0126

Interpretemos lo signos de los coeficientes para Muerte y Devolución:

- Muerte: a mayor edad, aumenta la probabilidad de Muerte sobre Adopción. Lo mismo pasa si el sexo del animal es macho. En cambio, ser perro y estar esterilizado reduce la probabilidad de muerte sobre Adopción.
- Devolución: Ser perro y estar esterilizado aumenta pronunciadamente la probabilidad de Devolución sobre Adopción. Los machos son más propensos a Devolución sobre Adopción. Y a mayor edad, aumenta la probabilidad de Devolución.


4 : Análisis de supervivencia

Analizamos ahora qué tan rápido ocurre una adopción. Para este análisis, el evento de interés es la adopción. Los demás desenlaces, es decir transferencia, devolución y muerte, se tratan como censura que significa que, para esos animales, sabemos que no fueron adoptados hasta el momento en que salieron del refugio, pero fue observada una adopción.

Ahora creamos la variable de evento:

- “1” si ocurrió el evento.
- “0” si el dato está censurado.

Ajustamos una curva de Kaplan-Meier para estimar la función de supervivencia $\hat{S}(t)$ que, en este contexto, representa la probabilidad estimada de que un animal siga sin ser adoptado luego de t días en el refugio.



La curva anterior muestra la probabilidad estimada de que el animal continúe sin ser adoptado a medida que pasan los días. Como el enunciado pide reportar la probabilidad de adopción estimada, calculamos el complemento de la supervivencia: $1 - \hat{S}(t)$

Este valor puede interpretarse como la probabilidad acumulada estimada de que un animal haya sido adoptado hasta el día t .

```
## # A tibble: 4 x 3
##   dias probabilidad_no_adopcion probabilidad_adopcion
##   <dbl>                <dbl>                <dbl>
## 1    30                  44.2                  55.8
## 2    60                  21.6                  78.4
## 3    90                  10.8                  89.2
## 4   180                   2.93                 97.1
```

En términos generales, la curva permite observar cómo aumenta la probabilidad acumulada de adopción a medida que transcurre el tiempo en el refugio. Los animales que tuvieron otros desenlaces aportan información hasta el momento en que salieron del refugio, pero luego se consideran censurados porque no se observa el evento de adopción.

Modelo de cox

Ajustaremos ahora un modelo de Cox para determinar otras variables asociadas con la rapidez de adopción de un animal. Este modelo permite estudiar cómo cambian las chances de adopción en función de las características del animal. De esta forma, un coeficiente positivo indica una adopción más rápida. Por el contrario, un coeficiente negativo indica una menor una adopción más lenta. El hazard ratio se interpreta

en relación con el tiempo hasta adopción. Un valor mayor a 1 indica que la variable está asociada con adopciones más rápidas. Un valor menor a 1 indica adopciones más lentas.

Se utilizarán variable como “age_years”, “dog”, “sterilized” y “sexo”. Estas variables fueron seleccionadas porque describen características observables del animal al momento de ingresar al refugio y permiten evaluar diferencias en la velocidad de adopción. No se incluyó “los”, ya que es la variable de tiempo del modelo, ni “desenlace”, porque se utiliza para definir el evento de adopción o la censura. Tampoco se incluyó “breed_main” en este modelo debido a la gran cantidad de categorías, lo que dificultaría la interpretación y podría generar estimaciones inestables para razas con pocos casos.

```
## # A tibble: 4 x 4
##   variable    coeficiente hazard_ratio p_value
##   <chr>      <dbl>      <dbl> <chr>
## 1 age_years   -0.0962      0.908 <0.001
## 2 dog         0.329       1.39  <0.001
## 3 sterilized  0.0855      1.09  <0.001
## 4 sexoMacho  -0.0543      0.947 <0.001
```


En base a los resultados se observa que las sig:

-observamos que la edad está asociada con tiempos de adopción más lentos. El hazard ratio de age_years es 0.9083, menor a 1, lo que indica que los animales de mayor edad presentan una menor tasa instantánea de adopción.

-La variable “dog” tiene un hazard ratio de 1.3895. Esto indica que, controlando por edad, esterilización y sexo, los perros tienen una mayor tasa instantánea de adopción que los gatos.

-La variable “sterilized” tiene un hazard ratio de 1.0893, por lo que estar esterilizado al ingresar se asocia con una adopción algo más rápida.

-Finalmente, “sexoMacho” tiene un hazard ratio de 0.9471. Al ser menor a 1, sugiere que los machos presentan una tasa instantánea de adopción ligeramente menor que las hembras, es decir, una adopción algo más lenta.



En conjunto, los resultados sugieren que los animales más jóvenes, perros, esterilizados y hembras tienden a presentar tiempos de adopción más rápidos. Por el contrario, los animales de mayor edad, gatos, no esterilizados y machos tienden a permanecer más tiempo sin ser adoptados.