

Trabajo Práctico 1: Modelado Estadístico

Sebastian Souto y Santiago Chiquinho

2026-06-27

1: Exploración Inicial

El **Austin Animal Center** es el refugio de animales municipal más grande de Estados Unidos. Cada animal que ingresa tiene, eventualmente, un desenlace: puede ser **adoptado**, **devuelto** a su dueño, **transferido** a otra organización, o sufrir **eutanasia/muerte**. El refugio publica todos sus registros de ingresos y egresos.


Para este trabajo se utilizará el dataset `refugio.csv`. Es un dataset (derivado de los registros públicos de `data.austintexas.gov`) en donde cada fila es un animal (perro o gato), con su tiempo de estadía y su desenlace.

Realizaremos una exploración inicial para conocer los datos:

Número de animales:

Tenemos datos de 137806 animales.

Distribución de desenlaces:



Se puede observar que el desenlace más común en los datos es “Adopción” por amplia mayoría.

Summary

Con el comando `summary` tenemos un resumen de cada columna del dataset.

```
##      animal_type      dog      sexo      sterilized
## Length :137806 Min. :0.0000 Length :137806 Min. :0.000
## N.unique : 2 1st Qu.:0.0000 N.unique : 2 1st Qu.:0.000
## N.blank : 0 Median :1.0000 N.blank : 0 Median :0.000
## Min.nchar: 3 Mean :0.5633 Min.nchar: 5 Mean :0.206
## Max.nchar: 3 3rd Qu.:1.0000 Max.nchar: 6 3rd Qu.:0.000
## Max. :1.0000 Max. :1.000
##      age_years      breed_main      los      desenlace
## Min. : 0.000 Length :137806 Min. : 0.00 Length :137806
## 1st Qu.: 0.083 N.unique : 473 1st Qu.: 3.11 N.unique : 4
## Median : 1.000 N.blank : 0 Median : 6.86 N.blank : 0
## Mean : 1.886 Min.nchar: 3 Mean : 20.68 Min.nchar: 6
## 3rd Qu.: 2.000 Max.nchar: 38 3rd Qu.: 23.06 Max.nchar: 13
## Max. :24.000 Max. :364.90
```

Podemos destacar que:

- 56.33% de los animales son perros y el resto gatos.
- Hay solo dos categorías para sexo y no hay datos faltantes.
- Aproximadamente el 20% de los animales están esterilizados.
- La mayoría de los animales son “jóvenes”. El 25% de ellos tiene menos de 0.083 años (~ 1 mes), la mediana es 1 año y el 75% tiene menos de 2 años. Existen algunos animales muy viejos, hasta 24 años.
- Hay 473 razas distintas.
- En promedio los animales pasan 20.68 días en el refugio. Y el 75% pasa menos de 23 días.


Glimpse

Con el comando “`glimpse()`” vemos el tipo de datos de cada columna y algunos valores de las mismas.

```
## Rows: 137,806
## Columns: 8
## $ animal_type <chr> "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "Dog", "C~
## $ dog <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1~
## $ sexo <chr> "Macho", "Macho", "Macho", "Hembra", "Hembra", "Macho", "M~
## $ sterilized <dbl> 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1~
## $ age_years <dbl> 6, 10, 16, 15, 15, 15, 15, 18, 16, 14, 16, 14, 17, 13, 19,~
## $ breed_main <chr> "Spinone Italiano Mix", "Dachshund", "Shetland Sheepdog", ~
## $ los <dbl> 1.11, 4.97, 0.12, 0.87, 0.18, 0.21, 6.26, 0.05, 3.90, 14.1~
## $ desenlace <chr> "Devolucion", "Transferencia", "Devolucion", "Devolucion",~
```

Sexo


Observamos la cantidad de machos y hembras que hay en perros y gatos.



En los gatos hay más hembras que machos. Mientras que en los perros sucede lo contrario.


Edades

Como habíamos visto en el summary, la mayor parte de los animales son jóvenes. Veamos si hay alguna diferencia si separamos entre perros y gatos.



En los histogramas divididos por tipo de animal notamos que los gatos tienen mayor concentración en edades que no llegan al año. Más del 70% de los gatos caen en este grupo, mientras que con los perros no sucede lo mismo.


Desenlaces según esterilización



En la mayoría de los desenlaces, la proporción de animales esterilizados y no esterilizados es similar a la observada en la muestra total. Sin embargo, en la categoría “Devolución” se observa una proporción considerablemente mayor de animales esterilizados, cercana al 50%, a pesar de que los animales esterilizados representan aproximadamente el 20% de la muestra.

Esto se puede deber a que los animales esterilizados tienen más probabilidad de tener un dueño previo. Y que este dueño lo reclame.

Tiempo de estadía



Los días de estadía muestran una distribución con una cola larga hacia la derecha. Y con acumulación en los primeros días

2: Estadística Bayesiana

Queremos estimar la tasa de adopción de cada raza. La estimación “obvia” es la tasa cruda: adoptados sobre total. Vamos a medir si conviene usar esa tasa o el estimador de Empirical Bayes.


Calculamos la “tasa verdadera” de cada raza como su tasa de adopción sobre toda la data (nos quedamos únicamente con las razas que tengan al menos 100 animales).

Table 1: Tasa verdadera de adopción por raza (Head)

Raza	Total	Adoptados	Tasa verdadera
Domestic Shorthair Mix	28638	14370	0.502
Domestic Shorthair	21359	13137	0.615
Pit Bull Mix	7456	3274	0.439
Labrador Retriever Mix	7187	4137	0.576
Chihuahua Shorthair Mix	6041	2948	0.488
Labrador Retriever	3913	2175	0.556

Vamos a simular el problema de estimar con poca data para ver cómo afecta esto. Tomamos una muestra aleatoria de 15 datos para cada raza y realizamos la estimación de la tasa cruda: $\text{adoptados}/15$.

Veamos gráficamente las diferencias:



En el gráfico podemos observar que, al tomar muestras más chicas, la estimación varía.

Estimador Empirical Bayes

Para calcular el estimador Empirical Bayes ajustamos una prior Beta sobre las tasas crudas de adopción observadas en las muestras chicas por raza.

Como la distribución Beta está definida en $(0,1)$, primero corregimos levemente las tasas crudas que sean exactamente 0 o exactamente 1. Esto puede pasar porque estamos usando muestras chicas de 15 animales por raza.

Luego ajustamos la distribución Beta usando máxima verosimilitud sobre las tasas de adopción ajustadas.

Los parámetros estimados fueron:

- $\alpha_0 = 2.499$
- $\beta_0 = 2.851$

Estos parámetros se utilizan para definir la distribución **a priori** de la tasa de adopción de cada raza.

A continuación, calculamos el estimador Empirical Bayes para la tasa de adopción de cada raza. Dado que se asume una distribución Beta como a priori y que el número de adopciones sigue una distribución Binomial, la distribución a posteriori es una Beta. Como estimador utilizamos la esperanza de la distribución a posteriori, dada por:

$$\hat{p}_i^{EB} = E[p_i | \text{datos}_i] = \frac{\alpha_0 + \text{adoptados}_i}{\alpha_0 + \beta_0 + m}$$

Calculamos el estimador para cada raza y comparamos.

Table 2: Comparación de tasas (Head)

Raza	Adopciones (m=15)	Tasa cruda	Empirical Bayes	Tasa verdadera
Domestic Shorthair Mix	5	0.333	0.369	0.502
Domestic Shorthair	13	0.867	0.762	0.615
Pit Bull Mix	7	0.467	0.467	0.439
Labrador Retriever Mix	10	0.667	0.614	0.576
Chihuahua Shorthair Mix	5	0.333	0.369	0.488
Labrador Retriever	8	0.533	0.516	0.556

El estimador Empirical Bayes combina la información observada para cada raza con una prior estimada a partir del comportamiento general de todas las razas. La tasa cruda puede ser muy inestable porque se calcula con solo 15 animales por raza. El estimador suaviza ese valor, acercándolo hacia la distribución general de tasas de adopción entre razas.

La comparación (métrica)


Con el fin de seleccionar un estimador por sobre el otro, calculamos el ECM de ambos contra la tasa verdadera.

Table 3: Comparación del ECM entre estimadores

Estimador	Error cuadrático medio
Tasa cruda	0.015012
Empirical Bayes	0.009481

La mejora porcentual del Empirical Bayes respecto de la tasa cruda es de : 36.84%.

Esto indica que, en este contexto de muestras chicas por raza, el suavizado bayesiano mejora la estimación de la tasa de adopción. Lo vemos más claramente con el siguiente gráfico.



La línea roja representa el caso ideal, en el que la tasa estimada coincide con la tasa verdadera. Se observa que la tasa cruda presenta una mayor dispersión debido al reducido tamaño muestral, mientras que el estimador Empirical Bayes produce estimaciones más cercanas a la línea de referencia al suavizar las tasas utilizando la información global. Cómo además presenta un menor ECM, puede concluirse que ofrece una mejor estimación en este contexto.

3: Modelo Multinomial

Para estos datos, si queremos modelar la probabilidad de los distintos desenlaces, no podemos utilizar una regresión logística binaria porque la variable respuesta tiene más de dos categorías posibles. En su lugar, se puede utilizar un modelo multinomial, que permite estimar la probabilidad de cada desenlace en función de las covariables observadas. Los parámetros del modelo se estiman mediante máxima verosimilitud, suponiendo que la variable respuesta sigue una distribución multinomial. Se fija una categoría de referencia y se modelan las probabilidades de la siguiente manera para cumplir con la restricción de que las probas sumen 1:

$$p_j(x) = \frac{\exp(\alpha_j + \beta_j x)}{1 + \sum_{l=2}^K \exp(\alpha_l + \beta_l x)}$$

$$p_1(x) = \frac{1}{1 + \sum_{l=2}^K \exp(\alpha_l + \beta_l x)}$$

1 siendo la categoría de referencia, j cualquier otra categoría, α y β los parámetros a estimar y x las covariables.

La función de verosimilitud que se maximiza es:

$$L(\theta) = \prod_{i=1}^n \prod_{j=1}^K p_j(x_i)^{y_{ij}}$$

donde y_{ij} es una variable indicadora que toma valor 1 si la observación i pertenece a la categoría j , y 0 en caso contrario.

De la formulación de las probabilidades, se llega a que el log-odds de una categoría respecto a la categoría de referencia tiene esta forma:

$$\log \left(\frac{p_j(x)}{p_1(x)} \right) = \alpha_j + \beta_j x$$

Esta expresión se puede utilizar para sacar conclusiones de los coeficientes obtenidos.

Ajustamos un modelo multinomial de 4 categorías en función de age_years, dog, sterilized y sexo. Con Adopción como referencia.

Y obtenemos los siguientes resultados:

Table 4: Coeficientes del modelo multinomial

	(Intercept)	age_years	dog	sterilized	sexoMacho
Devolucion	-3.4748	0.1662	1.7009	1.2524	0.2736
Muerte	-2.8917	0.2428	-0.7076	-0.3782	0.2582
Transferencia	-0.4906	0.0809	-0.4258	-0.2241	-0.0021

Interpretemos lo signos de los coeficientes para Muerte y Devolución:


- Muerte: a mayor edad, aumenta la probabilidad de Muerte sobre Adopción. Lo mismo pasa si el sexo del animal es macho. En cambio, ser perro y estar esterilizado reduce la probabilidad de muerte sobre Adopción.
- Devolución: Ser perro y estar esterilizado aumenta pronunciadamente la probabilidad de Devolución sobre Adopción. Los machos son más propensos a Devolución sobre Adopción. Y a mayor edad, aumenta la probabilidad de Devolución.

4 : Análisis de supervivencia

Analizamos ahora qué tan rápido ocurre una adopción. Para este análisis, el evento de interés es la adopción. Los demás desenlaces (transferencia, devolución y muerte) se tratan como censura ya que solo sabemos que el animal no fue adoptado hasta el momento en que salió del refugio. Definimos entonces una variable de evento que toma valor 1 si el animal fue adoptado y 0 si la observación está censurada.

Ajustamos una curva de Kaplan-Meier para estimar la función de supervivencia $\hat{S}(t)$ que, en este contexto, representa la probabilidad estimada de que un animal siga sin ser adoptado luego de t días en el refugio.

Curva de Kaplan–Meier para el tiempo hasta la adopción



Como el enunciado pide reportar la probabilidad de adopción estimada, calculamos el complemento de la supervivencia: $1 - \hat{S}(t)$

Este valor puede interpretarse como la probabilidad acumulada estimada de que un animal haya sido adoptado hasta el día t .

Table 5: Probabilidades estimadas de adopción mediante Kaplan-Meier

Días	P(No adopción)	P(Adopción)
30	0.442	0.558
60	0.216	0.784
90	0.109	0.891
180	0.029	0.971

En términos generales, la curva permite observar cómo aumenta la probabilidad acumulada de adopción a medida que transcurre el tiempo en el refugio.

Modelo de cox

Ajustamos un modelo de Cox para estudiar qué variables se asocian con la rapidez de adopción de un animal. En este modelo, un coeficiente positivo (hazard ratio mayor que 1) indica una mayor tasa de adopción, mientras que un coeficiente negativo (hazard ratio menor que 1) indica una menor tasa de adopción.

Como covariables se utilizaron age_years, dog, sterilized y sexo, ya que representan características observables del animal al ingresar al refugio. No se incluyeron los, por ser la variable de tiempo del modelo, ni desenlace, ya que define el evento o la censura. Tampoco se incorporó breed_main debido a su gran cantidad de categorías, lo que dificultaría la interpretación y podría producir estimaciones inestables para razas con pocos casos.

Table 6: Resultados del modelo de riesgos proporcionales de Cox

Variable	Coeficiente	Hazard Ratio	P Value
age_years	-0.0962	0.9083	<0.001
dog	0.3290	1.3895	<0.001
sterilized	0.0855	1.0893	<0.001
sexoMacho	-0.0543	0.9471	<0.001

En base a los resultados se observa lo siguiente:

- La edad está asociada con tiempos de adopción más lentos. El hazard ratio de age_years es 0.9083, menor a 1, lo que indica que los animales de mayor edad presentan una menor tasa instantánea de adopción.
- La variable “dog” tiene un hazard ratio de 1.3895. Esto indica que, controlando por edad, esterilización y sexo, los perros tienen una mayor tasa de adopción que los gatos.
- La variable “sterilized” tiene un hazard ratio de 1.0893, por lo que estar esterilizado al ingresar se asocia con una adopción algo más rápida.
- Finalmente, “sexoMacho” tiene un hazard ratio de 0.9471. Al ser menor a 1, sugiere que los machos presentan una tasa de adopción ligeramente menor que las hembras, es decir, una adopción algo más lenta.

En conjunto, los resultados sugieren que los animales más jóvenes, perros, esterilizados y hembras tienden a presentar tiempos de adopción más rápidos. Por el contrario, los animales de mayor edad, gatos, no esterilizados y machos tienden a permanecer más tiempo sin ser adoptados.