

Modelado Estadístico

Reglas del TP

1. Se hace en grupos de **2 o 3 personas**.
2. Se debe entregar un **informe en PDF** y el **código que lo genera** (un `.Rmd`). El informe **no** debe incluir código: solo responder las preguntas, mostrar los gráficos y contar las decisiones que fueron tomando. ¡La presentación importa!
3. El informe **no debe exceder las 8 páginas** (lo bueno y breve ...).
4. Pueden usar IA, pero deben **entender todo lo que escriben** en el informe y en el código.
5. Si fuera necesario, se puede llegar a pedir una **defensa oral** del TP.

El problema

El **Austin Animal Center** es el refugio de animales municipal más grande de Estados Unidos. Cada animal que ingresa tiene, eventualmente, un *desenlace*: puede ser **adoptado**, **devuelto** a su dueño, **transferido** a otra organización, o sufrir **eutanasia/muerte**. El refugio publica todos sus registros de ingresos y egresos.

Los datos

`refugio.csv` es un dataset (derivado de los registros públicos de `data.austintexas.gov`) en donde cada fila es **un animal** (perro o gato), con su tiempo de estadía y su desenlace. Las columnas:

- `animal_type` — "Dog" o "Cat".
- `dog` — 1 si perro, 0 si gato.
- `sexo` — "Macho" o "Hembra".
- `sterilized` — 1 si estaba castrado/esterilizado al ingresar.
- `age_years` — edad al ingresar, en años.
- `breed_main` — raza principal.
- `los` — *length of stay*: días que el animal pasó en el refugio.
- `desenlace` — una de **4 categorías**: Adopción, Transferencia, Devolución, Muerte.

Nota. El dataset contiene solo animales que ya egresaron, quedándonos con esas 4 categorías de desenlace. Cada animal cae en exactamente una.

1. EXPLORACIÓN INICIAL

Cargar `refugio.csv`. Reportar el número de animales y la distribución de los 4 desenlaces. Echar un vistazo a las variables (`summary`, `glimpse`). Hacer cualquier otra exploración de los datos que consideren apropiada.

2. Queremos estimar la tasa de adopción de cada raza. La estimación “obvia” es la tasa cruda: adoptados sobre total. Vamos a **medir** si conviene usar esa tasa o el estimador de Empirical Bayes.

- (a) Definir la “tasa verdadera” de cada raza como su tasa de adopción sobre **toda** la data (quedándose con razas de al menos 100 animales, para que esa verdad sea confiable).
- (b) Simular el problema de estimar con **poca data**: de cada raza, tomar una muestra aleatoria chica (por ejemplo, $m = 15$ animales). Calcular la tasa cruda en esa muestra.
- (c) Ajustar una prior $\text{Beta}(\alpha_0, \beta_0)$ sobre las tasas muestrales y calcular el estimador Empirical Bayes $\hat{p}_i^{EB} = (\alpha_0 + \text{adoptados}) / (\alpha_0 + \beta_0 + m)$.
- (d) **La comparación (métrica)**. Calcular el error cuadrático medio de cada estimador (crudo vs EB) contra la tasa verdadera. ¿Cuál gana? ¿Por cuánto? Graficar ambas estimaciones contra la tasa verdadera. Interpretar el resultado.

3. Para el refugio, **no es lo mismo** que un animal no-adoptado haya sido transferido a que haya sido eutanasiado. Modelemos los 4 desenlaces a la vez.

- (a) Investigar sobre el modelo multinomial y explicarlo con sus palabras.
- (b) Ajustar un modelo multinomial de 4 categorías en función de `age_years`, `dog`, `sterilized`, `sexo` (referencia: **Adopción**).
- (c) Interpretar el signo de los coeficientes de al menos dos categorías. Por ejemplo: ¿qué características empujan hacia **Muerte** en vez de **Adopción**?

4. Ahora el tiempo: ¿qué tan rápido se adoptan los animales? El **evento** es la adopción, y todo otro desenlace (transferencia, devolución, muerte) se trata como **censura**.

- (a) Estimar la curva de Kaplan-Meier ingenua (evento = adopción, resto censurado) y reportar la “probabilidad de adopción” estimada como $1 - \hat{S}(t)$ a los 30, 60, 90 y 180 días.
- (b) Determinar cuáles de las otras variables están asociadas con un tiempo de adopción más rápido o más lento.