

Trabajo Práctico 2: Modelado Estadístico

Sebastian Souto y Santiago Chiquinho

2026-07-24

1: Exploración Inicial:

Relación entre género y puntaje:


Primero agrupamos las películas por género y luego calculamos la media, mediana y desvío de las puntuaciones para cada género.

Table 1: Estadísticos descriptivos del puntaje IMDb por género

genres	Cantidad	Media	Mediana	Desvío estándar
	6	7.52	7.4	1.20
war	101	7.17	7.3	0.84
history	165	7.13	7.2	0.80
documentation	561	7.01	7.1	0.93
western	31	6.73	6.9	1.13
sport	122	6.72	7.0	1.29
animation	429	6.72	6.7	1.07
drama	1916	6.67	6.8	1.12
crime	576	6.67	6.8	1.03
music	157	6.67	6.8	1.11
fantasy	433	6.59	6.6	1.14
scifi	395	6.58	6.6	1.17
european	318	6.51	6.6	1.10
action	716	6.47	6.5	1.16
romance	646	6.44	6.5	1.17
comedy	1495	6.41	6.5	1.20
reality	128	6.39	6.6	1.39
thriller	787	6.37	6.4	1.20
family	430	6.33	6.4	1.21
horror	255	5.98	5.8	1.34

Podemos observar que para géneros como *War* o *History* la media es mayor a la de los demás géneros. Lo mismo sucede con la mediana. Mientras tanto el género que peor puntaje medio tiene es *Horror*. También podemos observar que en el dataset hay 6 películas que no tienen género.

Analicemos graficamente esta información:



Existe un importante solapamiento entre las distribuciones, por lo que el género por sí solo no parece explicar completamente el puntaje del título. Sin embargo podemos destacar diferencias en los géneros ubicados en lo más alto del gráfico y en lo más bajo. También notamos que hay géneros con más variabilidad, uno de ellos es *Drama*.

Actores y Directores

Observemos si hay actores y directores que tengan mejores valoraciones que los demás.

Table 2: Actores con mayor puntaje promedio de IMDb (mínimo 5 títulos)


name	Cantidad	IMDb_promedio
Yui Ishikawa	5	8.24
Terry Jones	7	8.07
Eric Idle	6	8.05
Graham Chapman	6	8.05
Terry Gilliam	5	8.04
Yoshimasa Hosoya	7	8.00

Table 3: Directores con mayor puntaje promedio de IMDb (mínimo 3 títulos)

name	Cantidad	IMDb_promedio
Kim Won-seok	3	8.70
Rajkumar Hirani	3	8.10
Bo Burnham	4	8.00

Mani Ratnam	4	7.92
Hong Jong-chan	5	7.90
Vikramaditya Motwane	4	7.82

Veamos los mejores y los peores actores:



En las tablas y el gráfico mostrado, se puede observar que hay ciertos directores y actores que tienen mejor puntuación en sus películas. Mientras que otros tienen menor puntuación.

Títulos

Vamos a analizar si hay palabras en los títulos que estén asociadas con un mayor puntaje. EL procedimiento consistió en dividir los títulos en palabras y tomar promedio de los puntajes en IMDb. Esto no lo realizaremos para cada palabra, sino que se van a eliminar las stopwords, es decir palabras muy comunes que no aportan información real. También nos quedamos con las palabras que tengan más de 8 apariciones.

Se obtuvieron los siguientes resultados:

Table 4: 5 palabras asociadas con títulos de mayor puntaje IMDb

Palabra	Cantidad	IMDb promedio
jim	9	7.57
art	8	7.55
inside	9	7.49
bheem	12	7.40
call	8	7.38

Table 5: 10 palabras asociadas con títulos de menor puntaje IMDb

Palabra	Cantidad	IMDb promedio
monsters	9	5.58
2	46	5.72
super	17	5.75
christmas	44	5.79
day	22	5.83
party	8	5.88
perfect	11	5.90
3	12	5.95
wedding	11	5.97
chance	9	6.07

En el caso de los mejores puntajes no pudimos encontrar un patrón, pero para los peores sí. Notamos que las películas que son secuelas o terceras partes y tienen “2” o “3” en el título se encuentran en la tabla de peores puntajes. Las películas peores valoradas, desde el punto de vista de este enfoque, tratan sobre monstruos. Y tenemos 44 películas navideñas que tienen puntaje bajo.

2: Causalidad

Dado el DAG presentado en el enunciado queremos estimar el efecto causal directo de Comedia sobre Score. Para ello debemos identificar todos los caminos entre Comedia y Score. Luego construir un conjunto Z de nodos que bloquee todos los caminos encontrados.

- Camino 1: Comedia $\leftarrow$ País $\rightarrow$ Score

Para bloquear este camino hay que agregar País a Z , ya que País es un confounder. Y es la única manera de bloquearlo.

- Camino 2: Comedia $\rightarrow$ Duración $\rightarrow$ Score

Para bloquear este camino hay que agregar Duración a Z , ya que Duración está en una cadena entre los nodos de interés. Y es la única manera de bloquearlo.

- Camino 3: Comedia $\rightarrow$ Duración $\leftarrow$ Año $\rightarrow$ Score

Notemos que Duración es un collider, una opción para bloquear este camino sería no agregar Duración pero esto no es posible ya que se abriría el camino 2. Por lo tanto, la única manera de bloquear este camino, es agregando Año, que en este camino juega un rol de confounder.

Finalmente, el único conjunto Z que d-separa a Comedia y Score es:

$$\{\text{Año}, \text{Duración}, \text{País}\}$$

Vamos a estimar el efecto causal directo, utilizando el conjunto Z y también realizaremos la estimación cruda. Para ello implementamos los respectivos modelos lineales.

Obteniendo los siguientes resultados:

Table 6: Comparación del coeficiente asociado a la variable Comedia

Modelo	Coeficiente_Comedia
Crudo	-0.206
Ajustado	-0.221

El modelo crudo muestra que los títulos clasificados como comedia presentan, en promedio, un puntaje IMDb 0,206 puntos menor que los títulos que no incluyen este género. Al ajustar por Año, Duración y País, el coeficiente estimado para Comedia es de -0,221. Por lo tanto, bajo los supuestos representados en el DAG, el efecto causal directo estimado indica que, manteniendo constantes dichas variables, los títulos de comedia tienen un puntaje IMDb aproximadamente 0,221 puntos menor.

La similitud entre ambos coeficientes muestra que el ajuste modifica poco la asociación observada: tanto la estimación cruda como la ajustada son negativas con valores similares. Sin embargo, la interpretación cambia, ya que el modelo ajustado busca aislar el efecto directo de Comedia, excluyendo el efecto mediado por la Duración y bloqueando los caminos no causales identificados en el DAG.

Para representar el País se utilizó el primer país informado en `production_countries`. Esta decisión permitió evitar una representación de alta dimensionalidad, generada por la gran cantidad de países y combinaciones de países presentes en los datos. Aunque esta simplificación no captura por completo las coproducciones, se consideró adecuada para realizar el ajuste requerido sin aumentar innecesariamente la complejidad del modelo.

3: Selección de modelos

Además de las variables disponibles en la base de títulos, se incorporó información proveniente de la base de créditos. En particular, se calculó para cada título la cantidad de actores y directores registrados.

Antes de ajustar los modelos, se analizaron los valores faltantes de las variables predictoras. En el caso de `seasons`, los faltantes correspondían a películas, para las cuales la cantidad de temporadas no resulta aplicable. Por este motivo, se reemplazaron por cero. La ausencia de `age_certification` se representó mediante una categoría adicional denominada “Sin dato”, evitando eliminar los títulos sin clasificación informada. Para los títulos sin información sobre la cantidad de votos de IMDb, se reemplazó el logaritmo de dicha variable por la mediana calculada exclusivamente sobre el conjunto de entrenamiento. Además, se incorporó una variable indicadora que identifica estas observaciones. El mismo tratamiento se aplicó posteriormente al conjunto de validación, evitando utilizar información de este último durante la preparación de los datos.

El siguiente paso es construir el **modelo base**, que predice siempre el promedio y nos da un MSE mínimo de referencia para evaluar si los modelos posteriores realmente aportan capacidad predictiva.

Modelo base

Como referencia inicial, se construyó un modelo base que predice para todos los títulos el puntaje IMDb promedio observado en el conjunto de entrenamiento. Este modelo obtuvo un MSE de 1.331 sobre el conjunto de validación.

Este resultado se utiliza como punto de comparación: para que un modelo con variables predictoras resulte útil, debería obtener un MSE menor que el del modelo base.

Table 7: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331

Primer modelo

Como primer modelo candidato se ajustó una regresión lineal múltiple. Se incluyeron características originales de los títulos, como el tipo de contenido, el año de lanzamiento, la duración, la cantidad de temporadas y la clasificación etaria. También se incorporaron la cantidad de votos transformada logarítmicamente y distintas variables derivadas de los géneros, países, créditos, títulos y descripciones.

Table 8: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331
Regresión lineal	1.035

El modelo lineal obtuvo un MSE de 1.035 en el conjunto de validación, frente a un MSE de 1.331 obtenido por el modelo base. La regresión intenta explicar el puntaje mediante una suma de contribuciones. Por ejemplo, estima cuánto cambia el score esperado ante diferencias en duración, año, votos o cantidad de actores, manteniendo constantes las demás variables. Su limitación es que supone relaciones esencialmente lineales. Por ejemplo, supone que el efecto de pasar de 60 a 70 minutos tiene la misma forma que el de pasar de 150 a 160.

Segundo modelo

Como segundo modelo candidato se ajustó una regresión con splines penalizados. En particular, se permitió que el año de lanzamiento, la duración y el logaritmo de la cantidad de votos tuvieran relaciones no lineales con el puntaje de IMDb. Las demás variables se incorporaron de la misma forma que en la regresión lineal, facilitando la comparación entre ambos modelos.

El grado de suavidad de las curvas fue seleccionado mediante REML, penalizando aquellas formas excesivamente complejas. De esta manera, el modelo puede capturar patrones no lineales sin ajustarse innecesariamente a las observaciones de entrenamiento.

Table 9: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331
Regresión lineal	1.035
Splines penalizados	0.969

La regresión con splines obtuvo un MSE de 0.969 en el conjunto de validación, frente a un MSE de 1.035 obtenido por la regresión lineal. El MSE baja aproximadamente 6,3% respecto de la regresión lineal y 27,2% respecto del modelo base. Esto sugiere que imponer relaciones estrictamente lineales era demasiado restrictivo y que existe información predictiva en las relaciones no lineales de variables como duración, año y cantidad de votos.

Tercer modelo

Como tercer modelo candidato se ajustó un árbol de regresión. Este modelo divide recursivamente el espacio de las variables predictoras en regiones y asigna a cada región una predicción correspondiente al puntaje promedio de los títulos que la integran. A diferencia de la regresión lineal, el árbol puede representar relaciones no lineales e interacciones entre variables sin que estas deban especificarse previamente.

Table 10: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331
Regresión lineal	1.035
Splines penalizados	0.969
Árbol de regresión	1.007

Inicialmente se permitió el crecimiento de un árbol relativamente flexible. Posteriormente, se seleccionó el parámetro de complejidad mediante validación cruzada de 10 particiones utilizando únicamente el conjunto de entrenamiento. Finalmente, el árbol fue podado con el objetivo de evitar divisiones que aumentarían la complejidad sin reducir suficientemente el error de predicción. El árbol podado quedó compuesto por 16 nodos terminales y obtuvo un MSE de 1.007 sobre el conjunto de validación. El árbol de regresión obtuvo un MSE de 1,007 en el conjunto de validación. Este resultado representa una mejora respecto de la regresión lineal, cuyo MSE fue de 1,034, lo que sugiere que la incorporación automática de relaciones no lineales e interacciones entre las variables aportó capacidad predictiva. Sin embargo, no mejora el resultado obtenido por el modelo de Splines.

Cuarto modelo.

Ahora, siguiendo la línea del modelo anterior, implementamos un Random Forest. Este método consiste en construir múltiples árboles de regresión sobre distintas muestras bootstrap del conjunto de entrenamiento. Además, en cada división de cada árbol se considera únicamente un subconjunto aleatorio de las variables predictoras, lo que introduce diversidad entre los árboles y reduce la correlación entre ellos. La predicción final se obtiene promediando las predicciones de todos los árboles del bosque.

Table 11: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331
Regresión lineal	1.035
Splines penalizados	0.969
Árbol de regresión	1.007
Random Forest	0.899

En este trabajo se construyó un bosque de 500 árboles y se fijó una semilla para garantizar la reproducibilidad de los resultados. El modelo obtuvo un MSE de validación de 0.899, siendo el mejor desempeño alcanzado hasta el momento. En particular, representa una mejora de aproximadamente un 7% respecto del modelo basado en splines cúbicos.

Quinto modelo

En esta sección implementamos diferentes modelos de efectos mixtos. Para este tipo de modelos es muy importante el proceso de diseño, donde elegiremos que efectos serán fijos y cuáles aleatorios. Para ello vamos

a implementar 3 modelos distintos, en el primero solo tomamos como efectos aleatorios al país, en el segundo al director y en el tercero ambos.

Table 12: Comparación del desempeño predictivo de los modelos

Modelo	MSE de validación
Modelo base	1.331
Regresión lineal	1.035
Splines penalizados	0.969
Árbol de regresión	1.007
Random Forest	0.899
Efectos mixtos (Director)	0.995
Efectos mixtos (País)	0.998
Efectos mixtos (D + P)	0.963