

Trabajo Práctico 2: Modelado Estadístico

Sebastian Souto

2026-07-20

1: Exploración Inicial:

Relación entre género y puntaje:


Primero agrupamos las películas por género y luego calculamos la media, mediana y desvío de las puntuaciones para cada género.

Table 1: Estadísticos descriptivos del puntaje IMDb por género

genres	Cantidad	Media	Mediana	Desvío estándar
	6	7.52	7.4	1.20
war	101	7.17	7.3	0.84
history	165	7.13	7.2	0.80
documentation	561	7.01	7.1	0.93
western	31	6.73	6.9	1.13
sport	122	6.72	7.0	1.29
animation	429	6.72	6.7	1.07
drama	1916	6.67	6.8	1.12
crime	576	6.67	6.8	1.03
music	157	6.67	6.8	1.11
fantasy	433	6.59	6.6	1.14
scifi	395	6.58	6.6	1.17
european	318	6.51	6.6	1.10
action	716	6.47	6.5	1.16
romance	646	6.44	6.5	1.17
comedy	1495	6.41	6.5	1.20
reality	128	6.39	6.6	1.39
thriller	787	6.37	6.4	1.20
family	430	6.33	6.4	1.21
horror	255	5.98	5.8	1.34

Podemos observar que para géneros como *War* o *History* la media es mayor a la de los demás géneros. Lo mismo sucede con la mediana. Mientras tanto el género que peor puntaje medio tiene es *Horror*. También podemos observar que en el dataset hay 6 películas que no tienen género.

Analicemos graficamente esta información:



Existe un importante solapamiento entre las distribuciones, por lo que el género por sí solo no parece explicar completamente el puntaje del título. Sin embargo podemos destacar que hay generos que presentan más variabilidad que otros, por ejemplo “drama” es un género con gran variabilidad.

Actores y Directores

Observemos si hay actores y directores que tengan mejores valoraciones que los demás.

Table 2: Actores con mayor puntaje promedio de IMDb (mínimo 5 títulos)


name	Cantidad	IMDb_promedio
Yui Ishikawa	5	8.24
Terry Jones	7	8.07
Eric Idle	6	8.05
Graham Chapman	6	8.05
Terry Gilliam	5	8.04
Yoshimasa Hosoya	7	8.00

Table 3: Directores con mayor puntaje promedio de IMDb (mínimo 3 títulos)

name	Cantidad	IMDb_promedio
Kim Won-seok	3	8.70
Rajkumar Hirani	3	8.10
Bo Burnham	4	8.00
Mani Ratnam	4	7.92

Hong Jong-chan	5	7.90
Vikramaditya Motwane	4	7.82

Veamos los mejores y los peores actores:



En las tablas y el gráfico mostrado, se puede observar que hay ciertos directores y actores que tienen mejor puntuación en sus películas. Mientras que otros tienen menor puntuación.

2: Causalidad

Dado el DAG presentado en el enunciado queremos estimar el efecto causal directo de Comedia sobre Score. Para ello debemos identificar todos los caminos entre Comedia y Score. Luego construir un conjunto Z de nodos que bloquee todos los caminos encontrados.

- Camino 1: Comedia $\leftarrow$ País $\rightarrow$ Score

Para bloquear este camino hay que agregar País a Z , ya que País es un confounder. Y es la única manera de bloquearlo.

- Camino 2: Comedia $\rightarrow$ Duración $\rightarrow$ Score

Para bloquear este camino hay que agregar Duración a Z , ya que Duración está en una cadena entre los nodos de interés. Y es la única manera de bloquearlo.

- Camino 3: Comedia $\rightarrow$ Duración $\leftarrow$ Año $\rightarrow$ Score

Notemos que Duración es un collider, una opción para bloquear este camino sería no agregar Duración pero esto no es posible ya que se abriría el camino 2. Por lo tanto, la única manera de bloquear este camino, es agregando Año, que en este camino juega un rol de confounder.

Finalmente, el único conjunto Z que d-separa a Comedia y Score es:

$$\{Año, Duración, País\}$$

Vamos a estimar el efecto causal directo, utilizando el conjunto Z y también realizaremos la estimación cruda. Para ello implementamos los respectivos modelos lineales.

Obteniendo los siguientes resultados:

Table 4: Comparación del coeficiente asociado a la variable Comedia

Modelo	Coeficiente_Comedia
Crudo	-0.206
Ajustado	-0.221