

# Trabajo Práctico 2: Modelado Estadístico

Sebastian Souto y Santiago Chiquinho

2026-07-30

## 1: Exploración Inicial:

### Relación entre género y puntaje:


Primero agrupamos las películas por género y luego calculamos la media, mediana y desvío de las puntuaciones para cada género.

Table 1: Estadísticos descriptivos del puntaje IMDb por género

| genres        | Cantidad | Media | Mediana | Desvío estándar |
|---------------|----------|-------|---------|-----------------|
|               | 6        | 7.52  | 7.4     | 1.20            |
| war           | 101      | 7.17  | 7.3     | 0.84            |
| history       | 165      | 7.13  | 7.2     | 0.80            |
| documentation | 561      | 7.01  | 7.1     | 0.93            |
| western       | 31       | 6.73  | 6.9     | 1.13            |
| sport         | 122      | 6.72  | 7.0     | 1.29            |
| animation     | 429      | 6.72  | 6.7     | 1.07            |
| drama         | 1916     | 6.67  | 6.8     | 1.12            |
| crime         | 576      | 6.67  | 6.8     | 1.03            |
| music         | 157      | 6.67  | 6.8     | 1.11            |
| fantasy       | 433      | 6.59  | 6.6     | 1.14            |
| scifi         | 395      | 6.58  | 6.6     | 1.17            |
| european      | 318      | 6.51  | 6.6     | 1.10            |
| action        | 716      | 6.47  | 6.5     | 1.16            |
| romance       | 646      | 6.44  | 6.5     | 1.17            |
| comedy        | 1495     | 6.41  | 6.5     | 1.20            |
| reality       | 128      | 6.39  | 6.6     | 1.39            |
| thriller      | 787      | 6.37  | 6.4     | 1.20            |
| family        | 430      | 6.33  | 6.4     | 1.21            |
| horror        | 255      | 5.98  | 5.8     | 1.34            |

Podemos observar que para géneros como *War* o *History* la media es mayor a la de los demás géneros. Lo mismo sucede con la mediana. Mientras tanto el género que peor puntaje medio tiene es *Horror*. También podemos observar que en el dataset hay 6 películas que no tienen género.

Analicemos graficamente esta información:



Existe un importante solapamiento entre las distribuciones, por lo que el género por sí solo no parece explicar completamente el puntaje del título. Sin embargo podemos destacar diferencias en los géneros ubicados en lo más alto del gráfico y en lo más bajo. También notamos que hay géneros con más variabilidad, uno de ellos es *Drama*.

## Actores y Directores

Observemos si hay actores y directores que tengan mejores valoraciones que los demás.

Table 2: Actores con mayor puntaje promedio de IMDb (mínimo 5 títulos)


| name             | Cantidad | IMDb_promedio |
|------------------|----------|---------------|
| Yui Ishikawa     | 5        | 8.24          |
| Terry Jones      | 7        | 8.07          |
| Eric Idle        | 6        | 8.05          |
| Graham Chapman   | 6        | 8.05          |
| Terry Gilliam    | 5        | 8.04          |
| Yoshimasa Hosoya | 7        | 8.00          |

Table 3: Directores con mayor puntaje promedio de IMDb (mínimo 3 títulos)

| name            | Cantidad | IMDb_promedio |
|-----------------|----------|---------------|
| Kim Won-seok    | 3        | 8.70          |
| Rajkumar Hirani | 3        | 8.10          |
| Bo Burnham      | 4        | 8.00          |

|                      |   |      |
|----------------------|---|------|
| Mani Ratnam          | 4 | 7.92 |
| Hong Jong-chan       | 5 | 7.90 |
| Vikramaditya Motwane | 4 | 7.82 |

Veamos los mejores y los peores actores gráficamente:



En las tablas y el gráfico mostrado, se puede observar que hay ciertos directores y actores que tienen mejor puntuación en sus películas, mientras que otros tienen menor puntuación. Y la diferencia es notoria entre estos “grupos”.

## Títulos

Vamos a analizar si hay palabras en los títulos que estén asociadas con un mayor puntaje. El procedimiento consistió en dividir los títulos en palabras y tomar promedio de los puntajes en IMDb. Esto no lo realizaremos para cada palabra, sino que se van a eliminar las stopwords, es decir palabras muy comunes que no aportan información real. También nos quedamos con las palabras que tengan más de 8 apariciones.

Se obtuvieron los siguientes resultados:

Table 4: 5 palabras asociadas con títulos de mayor puntaje IMDb

| Palabra | Cantidad | IMDb promedio |
|---------|----------|---------------|
| jim     | 9        | 7.57          |
| art     | 8        | 7.55          |
| inside  | 9        | 7.49          |
| bheem   | 12       | 7.40          |
| call    | 8        | 7.38          |

Table 5: 10 palabras asociadas con títulos de menor puntaje IMDb

| Palabra   | Cantidad | IMDb promedio |
|-----------|----------|---------------|
| monsters  | 9        | 5.58          |
| 2         | 46       | 5.72          |
| super     | 17       | 5.75          |
| christmas | 44       | 5.79          |
| day       | 22       | 5.83          |
| party     | 8        | 5.88          |
| perfect   | 11       | 5.90          |
| 3         | 12       | 5.95          |
| wedding   | 11       | 5.97          |
| chance    | 9        | 6.07          |

En el caso de los mejores puntajes no pudimos encontrar un patrón, pero para los peores sí. Notamos que las películas que son secuelas o terceras partes y tienen “2” o “3” en el título se encuentran en la tabla de peores puntajes. Las películas peores valoradas, desde el punto de vista de este enfoque, tratan sobre monstruos. Y tenemos 44 películas navideñas que tienen puntaje bajo.

## 2: Causalidad

Dado el DAG presentado en el enunciado queremos estimar el efecto causal directo de Comedia sobre Score. Para ello debemos identificar todos los caminos entre Comedia y Score. Luego construir un conjunto  $Z$  de nodos que bloquee todos los caminos encontrados.

- Camino 1: Comedia  $\leftarrow$  País  $\rightarrow$  Score

Para bloquear este camino hay que agregar País a  $Z$ , ya que País es un confounder. Y es la única manera de bloquearlo.

- Camino 2: Comedia  $\rightarrow$  Duración  $\rightarrow$  Score

Para bloquear este camino hay que agregar Duración a  $Z$ , ya que Duración está en una cadena entre los nodos de interés. Y es la única manera de bloquearlo.

- Camino 3: Comedia  $\rightarrow$  Duración  $\leftarrow$  Año  $\rightarrow$  Score

Notemos que Duración es un collider, una opción para bloquear este camino sería no agregar Duración pero esto no es posible ya que se abriría el camino 2. Por lo tanto, la única manera de bloquear este camino, es agregando Año, que en este camino juega un rol de confounder.

Finalmente, el único conjunto  $Z$  que d-separa a Comedia y Score es:

$$\{\text{Año}, \text{Duración}, \text{País}\}$$

Vamos a estimar el efecto causal directo, utilizando el conjunto  $Z$  y también realizaremos la estimación cruda. Para ello implementamos los respectivos modelos lineales.

Obteniendo los siguientes resultados:

Table 6: Comparación del coeficiente asociado a la variable Comedia

| Modelo   | Coeficiente_Comedia |
|----------|---------------------|
| Crudo    | -0.206              |
| Ajustado | -0.221              |

El modelo crudo muestra que los títulos clasificados como comedia presentan, en promedio, un puntaje IMDb 0,206 puntos menor que los títulos que no incluyen este género. Al ajustar por Año, Duración y País, el coeficiente estimado para Comedia es de -0,221. Por lo tanto, bajo los supuestos representados en el DAG, el efecto causal directo estimado indica que, manteniendo constantes dichas variables, los títulos de comedia tienen un puntaje IMDb aproximadamente 0,221 puntos menor.

La similitud entre ambos coeficientes muestra que el ajuste modifica poco la asociación observada: tanto la estimación cruda como la ajustada son negativas con valores similares. Sin embargo, la interpretación cambia, ya que el modelo ajustado busca aislar el efecto directo de Comedia, excluyendo el efecto mediado por la Duración y bloqueando los caminos no causales identificados en el DAG.

### 3: Selección de modelos

Además de las variables originales de la base de títulos, se incorporó información proveniente de la base de créditos. En particular, para cada título se calculó la cantidad de actores. A partir de la base de títulos también se construyeron variables derivadas, como la cantidad de países y de géneros registrados. En el caso de los géneros, se conservó únicamente el género principal de cada título, ya que la variable original contenía una lista de géneros y esta simplificación permitió incorporarla de manera sencilla en los modelos que requieren una única categoría por observación. Con la variable País también nos quedamos únicamente con un solo dato.

Antes de ajustar los modelos, se analizaron los valores faltantes de las variables predictoras. En el caso de **seasons**, los faltantes correspondían a películas, para las cuales la cantidad de temporadas no resulta aplicable. Por este motivo, se reemplazaron por cero. La ausencia de **age\_certification** se representó mediante una categoría adicional denominada “Sin dato”, evitando eliminar los títulos sin clasificación informada. Para los títulos sin información sobre la cantidad de votos de IMDb, se reemplazó el logaritmo de dicha variable por la mediana calculada exclusivamente sobre el conjunto de entrenamiento. El mismo tratamiento se aplicó posteriormente al conjunto de validación, evitando utilizar información de este último durante la preparación de los datos.

Luego de transformar las tablas originales y evaluar distintos conjuntos de variables, la mayoría de los modelos se entrenó utilizando como conjunto base de predictores las variables `type`, `release_year`, `runtime`, `seasons`, `age_certification`, `log_imdb_votes`, `votos_faltantes`, `genero_principal` y `pais`. A partir de este conjunto base, algunos modelos incorporaron variables o estructuras adicionales según sus características.

El siguiente paso es construir el modelo base, que predice siempre el promedio y nos da un MSE mínimo de referencia para evaluar si los modelos posteriores realmente aportan capacidad predictiva.

#### Modelo base

Como referencia inicial, se construyó un modelo base que predice para todos los títulos el puntaje IMDb promedio observado en el conjunto de entrenamiento. Este modelo obtuvo un MSE de 1.335 sobre el conjunto de validación.

Este resultado se utiliza como punto de comparación: para que un modelo con variables predictoras resulte útil, debería obtener un MSE menor que el del modelo base.

Table 7: Comparación del desempeño predictivo de los modelos

| Modelo      | MSE de validación |
|-------------|-------------------|
| Modelo base | 1.335             |

### Primer modelo

Como primer modelo candidato se ajustó una **regresión lineal múltiple**. Se incluyeron características originales de los títulos, como el tipo de contenido, el año de lanzamiento, la duración, la cantidad de temporadas y la clasificación etaria. También se incorporaron la cantidad de votos transformada logarítmicamente, el país y género principal.

Table 8: Comparación del desempeño predictivo de los modelos

| Modelo           | MSE de validación |
|------------------|-------------------|
| Modelo base      | 1.335             |
| Regresión lineal | 0.950             |

El modelo lineal obtuvo un MSE de 0.95 en el conjunto de validación, frente a un MSE de 1.335 obtenido por el modelo base. La regresión intenta explicar el puntaje mediante una suma de contribuciones. Su limitación es que supone relaciones esencialmente lineales.

### Segundo modelo

Como segundo modelo candidato se ajustó una regresión con **splines penalizados**. En particular, se permitió que el año de lanzamiento, la duración y el logaritmo de la cantidad de votos tuvieran relaciones no lineales con el puntaje de IMDb. Las demás variables se incorporaron de la misma forma que en la regresión lineal, facilitando la comparación entre ambos modelos.

El grado de suavidad de las curvas fue seleccionado mediante REML, penalizando aquellas formas excesivamente complejas. De esta manera, el modelo puede capturar patrones no lineales sin ajustarse innecesariamente a las observaciones de entrenamiento.

Table 9: Comparación del desempeño predictivo de los modelos

| Modelo              | MSE de validación |
|---------------------|-------------------|
| Modelo base         | 1.335             |
| Regresión lineal    | 0.950             |
| Splines penalizados | 0.878             |

La regresión con splines obtuvo un MSE de 0.878 en el conjunto de validación, frente a un MSE de 0.95 obtenido por la regresión lineal. Esto sugiere que imponer relaciones estrictamente lineales era demasiado restrictivo y que existe información predictiva en las relaciones no lineales de variables como duración, año y cantidad de votos.

### Tercer modelo

Como tercer modelo candidato se ajustó un **árbol de regresión**. Este modelo divide recursivamente el espacio de las variables predictoras en regiones y asigna a cada región una predicción correspondiente al

puntaje promedio de los títulos que la integran. A diferencia de la regresión lineal, el árbol puede representar relaciones no lineales e interacciones entre variables sin que estas deban especificarse previamente.

Table 10: Comparación del desempeño predictivo de los modelos

| Modelo              | MSE de validación |
|---------------------|-------------------|
| Modelo base         | 1.335             |
| Regresión lineal    | 0.950             |
| Splines penalizados | 0.878             |
| Árbol de regresión  | 0.995             |

El árbol podado quedó compuesto por 17 nodos terminales y obtuvo un MSE de 0.995 sobre el conjunto de validación.

#### Cuarto modelo

Ahora, siguiendo la línea del modelo anterior, implementamos un **Random Forest**. Este método consiste en construir múltiples árboles de regresión sobre distintas muestras bootstrap del conjunto de entrenamiento. Además, en cada división de cada árbol se considera únicamente un subconjunto aleatorio de las variables predictoras, lo que introduce diversidad entre los árboles y reduce la correlación entre ellos. La predicción final se obtiene promediando las predicciones de todos los árboles del bosque.

Table 11: Comparación del desempeño predictivo de los modelos

| Modelo              | MSE de validación |
|---------------------|-------------------|
| Modelo base         | 1.335             |
| Regresión lineal    | 0.950             |
| Splines penalizados | 0.878             |
| Árbol de regresión  | 0.995             |
| Random Forest       | 0.871             |

En este trabajo se construyó un bosque de 500 árboles y se fijó una semilla para garantizar la reproducibilidad de los resultados. El modelo obtuvo un MSE de validación de 0.871, siendo el mejor desempeño alcanzado hasta el momento.

#### Quinto modelo

En esta sección implementamos distintos **modelos de efectos mixtos**. En este tipo de modelos, el diseño de la estructura de efectos fijos y aleatorios resulta fundamental, ya que determina qué parte de la variabilidad se explica mediante covariables observadas y cuál se atribuye a diferencias entre grupos. En los tres modelos consideramos como efectos fijos las variables `type`, `release_year`, `runtime`, `seasons`, `age_certification`, `log_imdb_votes`, `votos_faltantes`, `comedia`, `cantidad_generos` y `cantidad_actores`. A partir de esta estructura base, fuimos incorporando distintos efectos aleatorios para evaluar su impacto en el desempeño predictivo.

El primer modelo incluye únicamente un intercepto aleatorio por país. El segundo agrega, además, un intercepto aleatorio por director. Finalmente, el tercer modelo incorpora también un intercepto aleatorio por género principal y permite que el efecto de la duración (`runtime`) varíe entre países mediante una pendiente aleatoria (`runtime | pais`).

Table 12: Comparación del desempeño predictivo de los modelos

| Modelo                                   | MSE de validación |
|------------------------------------------|-------------------|
| Modelo base                              | 1.335             |
| Regresión lineal                         | 0.950             |
| Splines penalizados                      | 0.878             |
| Árbol de regresión                       | 0.995             |
| Random Forest                            | 0.871             |
| Efectos mixtos (País)                    | 0.940             |
| Efectos mixtos (País y Director)         | 0.902             |
| Efectos mixtos (País, Director y Género) | 0.903             |

Como se observa en la tabla, el tercer modelo supera a los demás modelos de efectos mixtos. Pero no llega a mejorar el resultado obtenido con el random forest.

### Sexto Modelo

Como sexto modelo implementamos una **red neuronal** incorporando, además de las variables estructuradas utilizadas previamente, la información textual del título y la descripción. Para ello, se utilizó un modelo basado en BERT ajustado como sentence-transformer, que permite transformar los textos en representaciones numéricas (embeddings).

Luego usamos estos embeddings y las variables utilizadas para los otros modelos como entrada de una red neuronal multicapa. El modelo fue entrenado con validación early-stopping para evitar overfitting y conservar los mejores pesos obtenidos.

Table 13: Comparación del desempeño predictivo de los modelos

| Modelo                                   | MSE de validación |
|------------------------------------------|-------------------|
| Modelo base                              | 1.335             |
| Regresión lineal                         | 0.950             |
| Splines penalizados                      | 0.878             |
| Árbol de regresión                       | 0.995             |
| Random Forest                            | 0.871             |
| Efectos mixtos (País)                    | 0.940             |
| Efectos mixtos (País y Director)         | 0.902             |
| Efectos mixtos (País, Director y Género) | 0.903             |
| Red Neuronal                             | 1.000             |

El modelo alcanzó un MSE de validación de X, siendo el mejor resultado obtenido hasta el momento.

El código de este modelo se encuentra en el archivo modelo6.py, ya que Python cuenta con librerías con mayor soporte para la implementación y entrenamiento de modelos de aprendizaje profundo.

### Conclusión

Concluyendo, todos los modelos evaluados mejoraron el desempeño del modelo base, cuyo MSE fue de 1,335. La regresión lineal redujo el error a 0.95, mientras que la incorporación de relaciones no lineales mediante splines penalizados permitió alcanzar un MSE de 0.878. El árbol de regresión obtuvo un error de 0.995, pero su extensión mediante Random Forest mejoró la capacidad predictiva y alcanzó un MSE de 0.871. Los modelos de efectos mixtos también presentaron un buen desempeño. La incorporación sucesiva de interceptos aleatorios para país, director y género redujo el MSE y finalmente se llegó a 0.903.



## 4: Competencia

Dentro de la partición de entrenamiento y validación utilizada, el menor MSE correspondió al modelo basado en redes neuronales. Por este motivo, se lo seleccionó como modelo final para generar las predicciones solicitadas.

Sin embargo, su diferencia respecto de Random Forest, cuyo MSE fue de 0,871, es reducida, por lo que ambos modelos mostraron un desempeño predictivo muy similar. Realizaremos las predicciones para los dos modelos.