

Modelado Estadístico

Modelos mixtos, splines penalizados y causalidad


Reglas del TP

1. Se hace en grupos de **2 o 3 personas**.
2. Se debe entregar un **informe en PDF**, el **código que lo genera** (un `.Rmd`) y el **archivo de predicciones** que se detalla en el último ítem. El informe **no** debe incluir código: solo responder las preguntas, mostrar los gráficos y contar las decisiones que fueron tomando. ¡La presentación importa!
3. El informe **no debe exceder las 8 páginas**.
4. Pueden usar IA, pero deben **entender todo lo que escriben** en el informe y en el código.
5. Si fuera necesario, se puede llegar a pedir una **defensa oral** del TP.



En el archivo `titles_train.csv` se presentan 3631 títulos de una plataforma de streaming (películas y series). El archivo `credits_train.csv` contiene los actores y directores de esos títulos. La idea del trabajo es **predecir la calificación de IMDB** (`imdb_score`) a partir de otras covariables. A lo largo de todo el trabajo se usa la **pérdida cuadrática** para evaluar los modelos.

1. (Opcional — no se evalúa, pero ayuda para los dos últimos ítems.) Hacer un análisis exploratorio de los datos. Algunas ideas:
 - (a) ¿Hay algún género que parezca estar más asociado con el puntaje del título?
 - (b) ¿Hay algún actor o director asociado con puntajes más altos o más bajos?
 - (c) (Más difícil) ¿Hay palabras de la descripción o del nombre del título asociadas con un mayor o menor puntaje?
2. **Causalidad.** Se tiene el siguiente DAG:



donde **Comedia** es una variable binaria que indica si el género del título incluye comedia. ¿A qué subconjunto de las variables **Año**, **Duración** y **País** se debe condicionar para estimar el **efecto causal directo** de **Comedia** sobre el **Score** —es decir, el efecto que *no* está mediado por la **Duración**—? Dar todas las posibilidades y justificar. Luego **estimar ese efecto** con una regresión sobre los datos (**Comedia** sale de **genres**, **Duración** de **runtime**, **Año** de **release_year** y **País** de **production_countries**) y compararlo con la asociación *cruda* de **Comedia** sobre **Score** (sin ajustar por nada).

3. **Selección de modelos.** Dividir el conjunto de datos en **entrenamiento y testeo** (también pueden usar otra técnica, como validación cruzada). Con todas las variables disponibles, probar **al menos 5 modelos diferentes** y **mostrar la estimación del error cuadrático medio (MSE)** de cada uno. Entre los modelos candidatos deben incluir **sí o sí** al menos un modelo de **efectos mixtos** y una **regresión con splines**. Elegir el modelo que minimice el MSE de predicción para el rating de IMDB.
4. **Competencia.** En los archivos `titles_test.csv` y `credits_test.csv` aparecen 1652 nuevos títulos, para los cuales no se incluye el rating de IMDB (pero yo sí lo tengo). A partir del modelo elegido en el ítem anterior, producir un archivo `predicciones_<apellido1>_<apellido2>_<apellido3>.csv` con **una sola columna y sin encabezado**, donde la fila i contenga la predicción del rating de IMDB para el título de la fila i (debe tener tantas filas como el test). A partir de esas predicciones, yo voy a computar el error cuadrático medio de cada equipo, y gana el que tenga el menor.